

# Prova 2 Bimestre Raciocínio Probabilístico em IA

Vinicius Feld

E-mail: `vinicius.feld@utp.edu.br`

## 0.1 Introdução

Este artigo é baseado na análise de trabalhos realizados na área de inteligência artificial que utilizam o raciocínio probabilístico para resolução dos problemas, nos quais utilizam algoritmos complexos para resoluções de problemas como Redes Bayesianas, Cadeias de Markov, entre outros.

## 0.2 Fundamentação Teórica

### 0.2.1 Ponderação de Probabilidade

O algoritmo de ponderação de probabilidade evita o descarte de amostras que ocorre para a amostragem por rejeição. Desta forma, gera apenas amostras que possuem o valor instanciado da variável-evidência, ou seja, fixa valores para as evidências e amostra as demais variáveis. Para Rede Bayesiana aplicamos com 100 repetições.

### 0.2.2 Gibbs Sampling

A idéia básica deste algoritmo é gerar cada evento a partir do estado atual da rede, ou seja, podemos imaginar que a rede se encontra em um determinado estado e cada variável possui um valor específico. Assim, o próximo estado é gerado por uma passagem aleatória

dependente do estado atual. Para esse tipo de procedimento, as variáveis de evidências são consideradas fixas.

### 0.2.3 Amostragem por Rejeição

A idéia básica deste algoritmo é percorrer toda a rede, dada a estrutura de arcos e CPTs, gerando  $N$  amostras e verificando se aquele tipo de amostra é consistente, ou seja, se ela contém a evidência dada. Caso isso não ocorra, tal amostra é rejeitada.

### 0.2.4 Método de Metropolis - Hastings (MH)

O algoritmo de MH é a principal generalização de ARMS. Ele permite que a distribuição proposta assuma qualquer forma, sendo necessário apenas que  $g(x)$  possua ao menos o mesmo suporte que  $f(x)$ . Assim  $g$  pode ser desenvolvido a partir de ARMS, pode ser dado por uma Uniforme, uma Normal e assim por diante.

## 0.3 Análise dos Problemas

### 0.3.1 Rede Bayesianas

O algoritmo de ponderação de probabilidade serve para resolver o problema de Rede

Bayesiana. É um algoritmo de rápida convergência, sendo esses valores de probabilidade mais precisos do que os gerados pelo algoritmo de rejeição. Segundo Russel e Norvig, esse algoritmo é muito eficiente, porém pode sofrer degradação quando o número de evidências aumenta.

Outro algoritmo para resolver o problema de Rede Bayesiana é o Gibbs Sampling. Para uma boa funcionalidade do algoritmo alguns conceitos são importantes como probabilidade de transição e cobertura de Markov são importantes para a aplicação desse algoritmo. Mesmo assim, tal algoritmo não é frequentemente implementado em softwares básicos de Redes Bayesianas, devido a sua complexidade de manipulação das probabilidades para cada estado da rede.

O algoritmo de Amostragem por Rejeição funciona para resolução de Rede Bayesiana. Esse algoritmo torna-se preciso com o aumento do número de repetições, porém seu maior problema é o descarte de um grande número de amostras geradas, note que anteriormente apenas 18 amostras foram utilizadas em um total de 100 repetições. Segundo Russel e Norvig, o número de amostras consistentes é ainda menor quando aumentamos o número de variáveis-evidência.

O Método de Metropolis (ou Metropolis Hastings) é um algoritmo que traz a solução para as cadeias de Markov. Porém esse método não promove uma amostra de valores independentes. Esta é uma característica de processos estocásticos Markovianos. Casos de estudo apontam o algoritmo proposto como uma boa alternativa a métodos existentes, promovendo estimativas mais precisas sob um menor consumo de recursos computacionais em muitas situações

Podemos observar que o termo "infe-

rência", neste contexto, está intimamente ligado à verificação de probabilidades condicionais após a observação de determinadas informações, denominadas evidências. Para isso, utilizamos métodos específicos para diferentes tipos de estrutura.

Com isso, notamos que, dependendo do tipo de algoritmo utilizado, teremos esforços computacionais diferenciados de processamento, relacionados ao alto grau de complexidade do algoritmo e da estrutura em questão.

## 0.4 Resultados Experimentais




Figura 1. Convergência de probabilidade em Amostragem por Rejeição.




Figura 2. Convergência de probabilidade em

Ponderação de Probabilidade.




Figura 3. Cobertura de Markov de A representada pelas variáveis-nó cinza.

## 0.5 Considerações Finais

Nesse artigo foi possível observar alguns algoritmos utilizados na resolução de problemas, usando o Raciocínio Probabilístico, são eles: ponderação de probabilidade, Gibbs Sampling, Amostragem por Rejeição, Método de Metropolis - Hastings (MH). Observamos também como funciona cada um desses algoritmos e como podemos resolver usando o Raciocínio Probabilístico da melhor maneira. Todos os algoritmos foram escolhidos para se encaixar melhor e trazer uma melhor solução para cada problema apresentando.



## REFERÊNCIAS

Anderson Luiz Ara-Souza. *Redes Bayesianas*. 2010. Disponível em: <[http://www.ime.unicamp.br/sinape/sites/default/files/Anderson%20L.%20Souza%20-%20Redes%20Bayesianas-%20vSINAPE%20final\\_0.pdf](http://www.ime.unicamp.br/sinape/sites/default/files/Anderson%20L.%20Souza%20-%20Redes%20Bayesianas-%20vSINAPE%20final_0.pdf)>.

Jaime Shinsuke Ide. *Raciocínio Probabilístico em Sistemas Embarcados*. 2010. Disponível em: <[http://sites.poli.usp.br/pmr/ltd/people/jside/IdeCozman\\_enia01.pdf](http://sites.poli.usp.br/pmr/ltd/people/jside/IdeCozman_enia01.pdf)>.

Paulo Renato Alves Firmino. *Método Adaptativo de Markov Chain Monte Carlo*. 2009. Disponível em: <[https://repositorio.ufpe.br/bitstream/123456789/4950/1/arquivo3632\\_1.pdf](https://repositorio.ufpe.br/bitstream/123456789/4950/1/arquivo3632_1.pdf)>.

Paulo Renato Alves Firmino. *Método adaptativo de Markov Chain Monte Carlo para manipulação de modelos Bayesianos*. 2009. Disponível em: <<https://repositorio.ufpe.br/handle/123456789/4950>>.

(Anderson Luiz Ara-Souza, 2010)

(Paulo Renato Alves Firmino, 2009a)

(Jaime Shinsuke Ide, 2010)

(Paulo Renato Alves Firmino, 2009b)